هوتن سیفی

مهندس هوش مصنوعی | توسعهٔ سیستم‌های مبتنی بر LLM و هوش مصنوعی عامل‌محور

AI Engineer | LLM Applications & Agentic AI Systems · Python · FastAPI · LangGraph · RAG

تهران · 0935 775 9499 · hootanseifi90@gmail.com · پایان خدمت

سایت و نمونه‌کار زنده: hootanseifi.pro · **گیت‌هاب:** github.com/hootanseifi · **لینکدین:** linkedin.com/in/hootan-seifi-42b180124

آمادهٔ همکاری حضوری، دورکاری، ترکیبی و پروژه‌ای

خلاصهٔ حرفه‌ای

مهندس هوش مصنوعی با تمرکز بر طراحی، توسعه، ارزیابی و استقرار اپلیکیشن‌های مبتنی بر مدل‌های زبانی بزرگ (LLM)، سیستم‌های بازیابی اطلاعات (RAG) و عامل‌های هوشمند (AI Agents).

دارای تجربهٔ عملی در توسعهٔ سیستم‌های Agentic مبتنی بر LangGraph، بازیابی ترکیبی اطلاعات، ارزیابی کیفیت خروجی مدل‌ها، پیاده‌سازی کنترل‌های امنیتی و استقرار سرویس‌های مبتنی بر هوش مصنوعی. نمونه‌کارهای عملی شامل یک سیستم پرسش‌وپاسخ دوزبانه مبتنی بر اسناد، یک پلتفرم عامل هوشمند سازمانی و یک سیستم شبیه‌سازی معاملات متشکل از هفت عامل هوشمند است.

دارای مدرک کارشناسی ارشد مهندسی برق، گرایش هوش مصنوعی، و سابقهٔ فعالیت در حوزه‌های تحقیق و توسعه، تحلیل فنی نرم‌افزار و بازارهای مالی.

مهارت‌های فنی

LLM و عامل‌های هوشمند: Python، LangGraph، LangChain، OpenAI Agents SDK، CrewAI، MCP، Tool Calling، Prompt Engineering، Structured Outputs، Guardrails، LLM Evaluation، QLoRA / PEFT

RAG و بازیابی اطلاعات: PostgreSQL، pgvector، Chroma، Embeddings، Chunking، Hybrid Search (BM25 + Vector Search)، Reranking، Recall@k، MRR

بک‌اند و مهندسی نرم‌افزار: FastAPI، REST API، SQLAlchemy، Alembic، SSE، pytest، Playwright، Git

یادگیری ماشین و داده: PyTorch، scikit-learn، XGBoost، Pandas، SQL

فرانت‌اند: TypeScript، Next.js

زیرساخت و استقرار: Docker، Docker Compose، Linux، Caddy، GitHub Actions، CI/CD

آشنایی با ابزارها و پلتفرم‌ها: AWS (Bedrock، Lambda، SageMaker)، Modal، Vercel، Terraform، Kafka، Spark، Airflow

تجربهٔ مهندسی هوش مصنوعی

مهندس هوش مصنوعی (پروژه‌های مستقل) — خوداشتغال

مرداد ۱۴۰۵ – اکنون

سایت شخصی — hootanseifi.pro

توسعه و استقرار مجموعه‌ای از نمونه‌کارهای تعاملی هوش مصنوعی شامل سیستم پرسش‌وپاسخ مبتنی بر RAG، ارزیابی تناسب شغلی و شبیه‌سازی معاملات الگوریتمی.

- توسعهٔ یک دستیار هوشمند دوزبانه (فارسی و انگلیسی) مبتنی بر اسناد شخصی، با قابلیت پاسخ‌گویی مستند و ارجاع به منابع. پس از ارزیابی کیفیت بازیابی اطلاعات فارسی، معماری Hybrid Search مبتنی بر BM25 و pgvector با استفاده از Reciprocal Rank Fusion پیاده‌سازی شد. ارزیابی سیستم روی مجموعه‌ای شامل ۷۲ سناریوی داخلی، با پوشش پاسخ‌گویی مستند، امتناع از پاسخ در موارد فاقد پشتوانه و مقاومت در برابر Prompt Injection؛ موفقیت در هر ۷۲ سناریو.
- طراحی و پیاده‌سازی سیستم شبیه‌سازی معاملات متشکل از هفت عامل هوشمند مبتنی بر LangGraph، با استفاده از قیمت‌های لحظه‌ای بیت‌کوین برای تحلیل بازار، تصمیم‌گیری و اجرای معاملات آزمایشی. قوانین مدیریت ریسک، شامل سقف اهرم ۵ برابر، محدودیت مارجین و حد ضرر، در لایهٔ کد اعمال شده‌اند و وابسته به رعایت دستورالعمل توسط مدل نیستند. سیستم در ۲۰ جلسهٔ ارزیابی شبیه‌سازی‌شده، بدون نقض قوانین تعریف‌شده عمل کرد.
- توسعهٔ سیستم ارزیابی تناسب شغلی مبتنی بر LLM که محدودهٔ امتیاز نهایی را بر اساس میزان تطابق با مهارت‌های الزامی، در سطح کد کنترل می‌کند تا از امتیازدهی غیرواقع‌بینانهٔ مدل جلوگیری شود. همچنین برای افزایش تکرارپذیری خروجی‌ها، مقدار Temperature مدل روی صفر تنظیم شده است.
- پیاده‌سازی سازوکار کنترل هزینهٔ فراخوانی مدل‌ها با محدودیت بودجهٔ روزانه و ماهانه و بررسی اعتبار بودجه پیش از هر درخواست. همچنین، اجرای روزانهٔ سیستم به‌صورت مشترک مدیریت می‌شود؛ نخستین بازدیدکننده اجرای روز را فعال می‌کند و سایر کاربران نتیجهٔ همان اجرا را مشاهده می‌کنند.
- استقرار پنج سرویس شامل PostgreSQL، Worker، FastAPI، Next.js و Caddy روی سرور سخت‌سازی‌شده. پیاده‌سازی خط لولهٔ CI/CD با GitHub Actions، شامل اجرای Linter، تست‌های خودکار و اسکن اطلاعات محرمانه. مجموعهٔ تست‌ها شامل ۲۲۵ تست بک‌اند، ۲۸ تست کامپوننت و ۱۵ تست End-to-End است. همچنین، در صورت شکست استقرار، سیستم به‌صورت خودکار به نسخهٔ قبلی بازمی‌گردد؛ این قابلیت با انتشار عمدی یک نسخهٔ معیوب آزمایش شده است.

Astra — پلتفرم عامل هوشمند سازمانی github.com/hootanseifi/astra-ai-platform

- طراحی و پیاده‌سازی عامل هوشمند مبتنی بر LangGraph با قابلیت انتخاب پویای مسیر پردازش درخواست، شامل بازیابی اطلاعات (RAG)، فراخوانی ابزارها، ترکیب هر دو مسیر یا تولید پاسخ مستقیم.
- پیاده‌سازی Agentic RAG با استفاده از PostgreSQL و pgvector، ایندکس HNSW، بازرتبه‌بندی نتایج (Reranking) و کنترل سطح دسترسی کاربران در فرایند بازیابی اطلاعات. بازرتبه‌بندی، معیار Recall@1 را در مجموعه دادهٔ ارزیابی از ۰٫۶۷ به ۱٫۰۰ رساند.
- پیاده‌سازی لایهٔ امنیت و کنترل دسترسی شامل RBAC، احراز هویت JWT، فهرست مجاز ابزارها، اعتبارسنجی Schema ورودی و شناسایی Prompt Injection در متن فارسی و انگلیسی. همچنین، پیاده‌سازی قابلیت‌های عملیاتی شامل حذف اطلاعات محرمانه از خروجی‌ها، محدودسازی نرخ درخواست، ثبت متریک‌ها با Prometheus، ردیابی مصرف توکن و هزینه و ارائهٔ MCP Server.
- پیاده‌سازی ۴۰۷ تست خودکار با پوشش کد ۹۳ درصد و افزودن مرحلهٔ ارزیابی کیفیت به CI بر اساس معیارهای Recall@k، MRR، دقت مسیریابی و میزان اتکای پاسخ‌ها به منابع (Groundedness).

Price Estimate — سامانهٔ پیش‌بینی قیمت و شناسایی هوشمند تخفیف github.com/hootanseifi/price-estimate

- توسعه و بازمهندسی یک پروژهٔ پیش‌بینی قیمت محصولات آمازون در قالب یک پکیج Python تست‌شده، با استفاده از مجموعه داده‌ای شامل حدود ۸۰۰ هزار محصول. پیاده‌سازی و ارزیابی مدل‌های مختلف از Baseline و شبکهٔ عصبی عمیق تا Fine-tuning مدل Llama 3.2 3B با روش QLoRA و استفاده از Hugging Face TRL روی Modal.
- توسعهٔ خط لولهٔ مبتنی بر RAG و Chroma، بهینه‌سازی وزن مدل‌های Ensemble با روش NNLS و محاسبهٔ مجدد وزن‌ها در صورت در دسترس نبودن یکی از مدل‌ها. ارزیابی مدل‌ها روی مجموعهٔ آزمون یکسان با معیارهای MAE و بازهٔ اطمینان ۹۵ درصد، RMSLE، R^2 و Hit Rate. همچنین، توسعهٔ عامل‌های هوشمند برای پایش RSS و ارسال هشدار تخفیف، همراه با API مبتنی بر FastAPI، رابط کاربری Gradio و بیش از ۶۰ تست خودکار.

AI Medical Notes github.com/hootanseifi/ai-medical-notes-saas

- توسعهٔ سامانه‌ای برای پزشکان جهت تبدیل یادداشت‌های ویزیت به خلاصهٔ ساختاریافته، اقدامات پیشنهادی بعدی و پیش‌نویس ایمیل بیمار. ارسال نتایج به رابط کاربری به‌صورت لحظه‌ای با استفاده از Server-Sent Events (SSE). پیاده‌سازی با Next.js، FastAPI و OpenAI، همراه با احراز هویت و مدیریت اشتراک از طریق Clerk و استقرار روی Vercel.

بهنگام — پلتفرم یکپارچهٔ سلامت | بنیان‌گذار، مرحلهٔ طراحی و توسعهٔ نمونهٔ اولیه

- طراحی معماری پیشنهادی پلتفرمی برای اتصال ۱۲ گروه از ذی‌نفعان نظام سلامت ایران از طریق پروندهٔ مشترک بیمار. تدوین نقشهٔ راه محصول و طراحی نمونهٔ اولیهٔ تعاملی برای ارائه به سرمایه‌گذاران، با در نظر گرفتن یکپارچه‌سازی داده‌های آزمایشگاهی از طریق HL7 v2 و FHIR، استانداردسازی با LOINC و UCUM و استفاده از لایهٔ هشدار هوش مصنوعی. خروجی هوش مصنوعی صرفاً در نقش ابزار پشتیبان تصمیم‌گیری و پیشنهاد به پزشک طراحی شده است.

سوابق شغلی قبلی

مدیر بازاریابی دیجیتال و محتوا — اقتصاد گستر بهسامان اردیبهشت ۱۴۰۴ – فروردین ۱۴۰۵

- برنامه‌ریزی و مدیریت فعالیت‌های بازاریابی دیجیتال، تولید محتوا و بهینه‌سازی کانال‌های ارتباطی.

کارشناس ارشد نیروگاه — نیروگاه تأمین انرژی تابان (بانک پاسارگاد) اسفند ۱۴۰۳ – اردیبهشت ۱۴۰۴

- مسئولیت‌های فنی و نظارت بر عملکرد تجهیزات و فرایندهای عملیاتی نیروگاه.

تحلیلگر فاندامنتال و معامله‌گر بازارهای مالی — فناوری‌های نوین اقتصاد شهریور ۱۴۰۱ – بهمن ۱۴۰۳

- تحلیل بازارهای مالی و رمزارز، ارزیابی پروژه‌های بلاکچینی و تهیهٔ گزارش‌های تحلیلی، و توسعهٔ ربات معامله‌گر با Python بر اساس داده‌های بازار.

کارشناس فنی بررسی و توسعهٔ اپلیکیشن — کافه‌بازار دی ۱۴۰۰ – اردیبهشت ۱۴۰۱

- بررسی فنی اپلیکیشن‌ها، ارزیابی کیفیت عملکرد و همکاری در فرایند بررسی و انتشار برنامه‌ها.

کارشناس تحقیق و توسعه، واحد R&D — مهندسی و ساخت و کنترل مپنا (مکو) فروردین ۱۳۹۹ – اسفند ۱۳۹۹

- مشارکت در فعالیت‌های تحقیق و توسعه و بررسی فنی پروژه‌های مرتبط با حوزهٔ تخصصی شرکت.

تحصیلات و پروژه‌های دانشگاهی

کارشناسی ارشد مهندسی برق، گرایش هوش مصنوعی — دانشگاه صنعتی امیرکبیر، واحد تفرش | ۱۳۹۵ تا ۱۳۹۷

کارشناسی مهندسی برق، گرایش الکترونیک — دانشگاه صنعتی امیرکبیر، واحد تفرش | ۱۳۹۰ تا ۱۳۹۴

- تشخیص تقلب در تراکنش‌های اتریوم با استفاده از XGBoost و داده‌های نامتوازن.
- بررسی تأثیر احساسات توییت‌ها بر قیمت سهام با استفاده از روش‌های NLP و تحلیل سری زمانی.
- طبقه‌بندی علائم ترافیکی با استفاده از CNN و مجموعه‌دادهٔ GTSRB.

گواهینامه‌ها و زبان

LLM Engineering: Master AI, Large Language Models & Agents — Ed Donner, Udemy

Machine Learning Specialization — Andrew Ng, DeepLearning.AI & Stanford

Financial Trading in Python — DataCamp, 2025

فارسی: زبان مادری · انگلیسی: تسلط کاری حرفه‌ای (Professional Working Proficiency)