هوتن سیفی

مهندس هوش مصنوعی | توسعهٔ سیستم‌های مبتنی بر LLM و هوش مصنوعی عامل‌محور

AI Engineer | LLM Applications & Agentic AI Systems · Python · FastAPI · LangGraph · RAG

تهران · 0935 775 9499 · hootanseifi90@gmail.com · پایان خدمت
سایت و نمونه‌کار زنده: hootanseifi.pro · **گیت‌هاب:** github.com/hootanseifi · **لینکدین:** linkedin.com/in/hootan-seifi-42b180124
آمادهٔ همکاری حضوری، دورکاری، ترکیبی و پروژه‌ای

خلاصهٔ حرفه‌ای

مهندس هوش مصنوعی با تمرکز بر طراحی، توسعه، ارزیابی و استقرار سیستم‌های مبتنی بر مدل‌های زبانی بزرگ (LLM)، از جمله سیستم‌های RAG و عامل‌های هوشمند. در پروژه‌های عملی، سامانه‌های عامل‌محور مبتنی بر LangGraph، بازیابی ترکیبی اطلاعات، ارزیابی خروجی مدل‌ها، کنترل‌های امنیتی و زیرساخت استقرار را پیاده‌سازی کرده‌ام. نمونه‌کار زندهٔ من، **hootanseifi.pro**، شامل یک سیستم پرسش‌وپاسخ RAG مبتنی بر اسناد شخصی و یک سیستم معاملاتی شبیه‌سازی‌شده با هفت عامل هوشمند است که زیر سقف مشخص بودجهٔ هوش مصنوعی اجرا می‌شود. دارای کارشناسی ارشد مهندسی برق گرایش هوش مصنوعی، با سابقهٔ فعالیت در تحقیق و توسعه، بررسی فنی اپلیکیشن و تحلیل بازارهای مالی.

مهارت‌های فنی

مدل‌های زبانی بزرگ و عامل‌های هوشمند: LangGraph، LangChain، OpenAI Agents SDK، CrewAI، MCP، Tool Calling، Structured Outputs، Prompt Engineering، ارزیابی LLM، Guardrails، PEFT / QLoRA

بازیابی اطلاعات و RAG: PostgreSQL + pgvector، جست‌وجوی ترکیبی برداری و واژگانی (BM25)، Embedding، Chunking، Reranking، Chroma، MRR / Recall@k

بک‌اند و استقرار: Python، FastAPI، SQLAlchemy، Alembic، REST، SSE، Docker Compose، Caddy، Linux، GitHub Actions، pytest، Playwright

یادگیری ماشین: PyTorch، scikit-learn، XGBoost، Pandas، SQL؛ فرانت‌اند با Next.js و TypeScript

آشنایی: AWS (Bedrock، SageMaker، Lambda)، Terraform، Modal، Vercel، Spark، Kafka، Airflow

تجربهٔ مهندسی هوش مصنوعی

مهندس هوش مصنوعی (پروژه‌های مستقل) — خوداشتغال مرداد ۱۴۰۵ – اکنون

طراحی، توسعه، تست و استقرار کامل اپلیکیشن‌های مبتنی بر LLM و عامل‌های هوشمند. کد همهٔ پروژه‌ها در گیت‌هاب در دسترس است.

سایت hootanseifi.pro — نمونه‌کار زنده: سیستم پرسش‌وپاسخ RAG، ارزیابی تناسب شغلی، شبیه‌سازی معاملات

- توسعهٔ یک سیستم پرسش‌وپاسخ RAG دوزبانه (فارسی و انگلیسی) مبتنی بر اسناد شخصی، با پاسخ‌گویی مستند و ارجاع به منابع. پس از ارزیابی کیفیت بازیابی متن فارسی، معماری جست‌وجوی ترکیبی مبتنی بر BM25 و pgvector با Reciprocal Rank Fusion پیاده‌سازی شد. نتیجه در مجموعهٔ ارزیابی داخلی شامل سناریوهای امتناع از پاسخ و Prompt Injection: **۷۲ از ۷۲**.
- طراحی و پیاده‌سازی یک سیستم معاملاتی شبیه‌سازی‌شده متشکل از هفت عامل هوشمند مبتنی بر LangGraph که با قیمت لحظه‌ای بیت‌کوین، جلسهٔ تصمیم‌گیری و معاملات آزمایشی اجرا می‌کند. قوانین مدیریت ریسک (حداکثر اهرم ۵ برابر، حداکثر ۲۰ درصد مارجین و حد ضرر ۱ تا ۵ درصد) در لایهٔ کد اعمال می‌شود، نه در پرامپت مدل؛ **۲۰ جلسهٔ ارزیابی‌شده** بدون هیچ نقض قانون.
- توسعهٔ سیستم ارزیابی تناسب شغلی مبتنی بر LLM که محدودهٔ امتیاز نهایی را بر اساس میزان تطابق با مهارت‌های الزامی در سطح کد کنترل می‌کند تا از امتیازدهی غیرواقع‌بینانهٔ مدل جلوگیری شود؛ مقدار Temperature برای تکرارپذیری خروجی روی صفر تنظیم شده است.
- کنترل هزینهٔ فراخوانی مدل‌های هوش مصنوعی با سقف بودجهٔ روزانه و ماهانه که پیش از هر درخواست بررسی می‌شود، و سازوکار اجرای روزانه که در آن اولین بازدیدکننده جلسه را فعال می‌کند و سایر کاربران بازپخش همان اجرا را می‌بینند.
- استقرار پنج سرویس کانتینری شامل Next.js، FastAPI، Worker، PostgreSQL و Caddy روی یک سرور سخت‌سازی‌شده با پشتیبان‌گیری خودکار شبانه. خط لولهٔ CI/CD با GitHub Actions شامل Linter، **۲۲۵ تست بک‌اند، ۲۸ تست کامپوننت و ۱۵ تست End-to-End** و اسکن اطلاعات محرمانه است و در صورت شکست استقرار، به‌طور خودکار به نسخهٔ قبلی برمی‌گردد؛ این قابلیت با انتشار عمدی یک نسخهٔ معیوب آزمایش شد.

FastAPI · LangGraph · PostgreSQL + pgvector · SQLAlchemy · Next.js / TypeScript · Docker · Caddy · GitHub Actions

آسترا (Astra) — پلتفرم عامل هوشمند سازمانی github.com/hootanseifi/astra-ai-platform

- طراحی و پیاده‌سازی عامل هوشمند مبتنی بر LangGraph با تصمیم‌گیری پویا برای انتخاب مسیر اجرای هر درخواست: RAG، فراخوانی ابزار، ترکیب هر دو یا پاسخ مستقیم؛ شامل برنامه‌ریزی چندمرحله‌ای، گرهٔ بازیابی از خطا ((Recovery Node، ذخیرهٔ وضعیت اجرا با PostgreSQL Checkpointer و تأیید انسانی برای ابزارهای حساس.
- پیاده‌سازی Agentic RAG روی pgvector با ایندکس HNSW، بازرتبه‌بندی نتایج (Reranking) و بازیابی مبتنی بر سطح دسترسی کاربر. بازرتبه‌بندی، معیار Recall@1 را در مجموعه دادهٔ ارزیابی از **۰٫۶۷ به ۱٫۰۰** رساند.
- پیاده‌سازی لایهٔ امنیت و کنترل دسترسی (RBAC)، فهرست مجاز ابزارها، اعتبارسنجی Schema، احراز هویت JWT و شناسایی Prompt Injection در متون فارسی و انگلیسی) و قابلیت‌های عملیاتی (حذف اطلاعات محرمانه، محدودسازی نرخ درخواست، متریک‌های Prometheus، ردیابی مصرف توکن و هزینه و .(MCP Server
- **۴۰۷ تست خودکار با پوشش کد ۹۳ درصد** و مرحلهٔ ارزیابی کیفیت در CI بر اساس Recall@k، MRR، دقت مسیریابی و میزان اتکای پاسخ‌ها به منابع (Groundedness).

پیش‌بینی قیمت ((Price Estimate — پیش‌بینی قیمت و عامل‌های هوشمند شناسایی تخفیف github.com/hootanseifi/price-estimate

- پیاده‌سازی مجدد پروژهٔ پایانی دورهٔ (LLM Engineeringاد دانر) در قالب یک پکیج تست‌شدهٔ Python، با مجموعه داده‌ای شامل حدود ۸۰۰ هزار محصول آمازون: توسعه و ارزیابی مدل‌ها از Baseline تا شبکهٔ عصبی عمیق، خط لولهٔ Fine-tuning با QLoRA برای Llama 3.2 3B (Hugging Face TRL)، اجرا روی Modal) و خط لولهٔ RAG مبتنی بر LLM و .Chroma
- جایگزینی وزن‌های دستی Ensemble با وزن‌های بهینه‌شده به روش NNLS و محاسبهٔ مجدد وزن‌ها در صورت در دسترس نبودن یکی از مدل‌ها؛ رفع مشکلات Parser، آپلود فایل و Checkpoint در نسخهٔ اصلی.
- ارزیابی همهٔ مدل‌ها روی یک مجموعهٔ آزمون یکسان با MAE همراه با بازهٔ اطمینان ۹۵ درصد، RMSLE، R^2 و Hit Rate. عامل‌های هوشمند فیدهای RSS تخفیف را پایش و اعلان ارسال می‌کنند؛ همراه با API پیش‌بینی با FastAPI، رابط کاربری Gradio و بیش از ۶۰ تست خودکار در .CI

AI Medical Notes — سامانهٔ آنلاین برای پزشکان github.com/hootanseifi/ai-medical-notes-saas

- تبدیل یادداشت‌های ویزیت به خلاصهٔ ساختاریافته، اقدامات پیشنهادی بعدی و پیش‌نویس ایمیل بیمار؛ نتایج به‌صورت لحظه‌ای با Server-Sent Events به رابط کاربری ارسال می‌شود. Next.js، FastAPI، OpenAI، احراز هویت و اشتراک با Clerk، مستقر روی .Vercel

بهنگام — پلتفرم یکپارچهٔ سلامت (بنیان‌گذار، در مرحلهٔ طراحی) دموی تعاملی نسخهٔ ۲

- طراحی پلتفرمی برای اتصال ۱۲ گروه از ذی‌نفعان نظام سلامت ایران از طریق پروندهٔ مشترک بیمار. توسعهٔ دموی تعاملی برای ارائه به سرمایه‌گذاران و طراحی نقشهٔ راه محصول: دریافت داده‌های آزمایشگاهی با HL7 v2 و FHIR از طریق Kafka، استانداردسازی با LOINC و UCUM، بک‌اند Django REST با کنترل دسترسی نقش‌محور و لایهٔ هشدار هوش مصنوعی. خروجی هوش مصنوعی فقط به‌عنوان پیشنهاد در اختیار پزشک قرار می‌گیرد و جایگزین تصمیم پزشکی نمی‌شود.

سوابق شغلی قبلی

مدیر بازاریابی دیجیتال و محتوا — اقتصاد گستر بهسامان اردیبهشت ۱۴۰۴ – فروردین ۱۴۰۵

کارشناس ارشد نیروگاه — نیروگاه تأمین انرژی تابان (بانک پاسارگاد) اسفند ۱۴۰۳ – اردیبهشت ۱۴۰۴

تحلیلگر فاندامنتال و معامله‌گر بازارهای مالی — فناوری‌های نوین اقتصاد شهریور ۱۴۰۱ – بهمن ۱۴۰۳

- تحلیل بازارهای مالی و رمزارز، ارزیابی پروژه‌های بلاکچینی و تهیهٔ گزارش‌های تحلیلی، و توسعهٔ ربات معامله‌گر با Python بر اساس داده‌های بازار.

کارشناس فنی بررسی و توسعهٔ اپلیکیشن — کافه‌بازار دی ۱۴۰۰ – اردیبهشت ۱۴۰۱

کارشناس تحقیق و توسعه، واحد R&D — مهندسی و ساخت و کنترل مپنا (مکو) فروردین ۱۳۹۹ – اسفند ۱۳۹۹

تحصیلات

کارشناسی ارشد مهندسی برق، گرایش هوش مصنوعی — دانشگاه امیرکبیر (واحد تفرش) ۱۳۹۵ – ۱۳۹۷

کارشناسی مهندسی برق، گرایش الکترونیک — دانشگاه امیرکبیر (واحد تفرش) ۱۳۹۰ – ۱۳۹۴

پروژه‌های دانشگاهی یادگیری ماشین: تشخیص تقلب در تراکنش‌های اتریوم با داده‌های نامتوازن (XGBoost)؛ بررسی اثر احساسات توییت‌ها بر قیمت سهام (NLP Nvidia) و سری زمانی)؛ طبقه‌بندی علائم ترافیکی با (CNNمجموعه دادهٔ GTSRB).

گواهینامه‌های تخصصی و زبان

LLM Engineering: Master AI, Large Language Models & Agents — Ed Donner, Udemy
Machine Learning Specialization — Andrew Ng, DeepLearning.AI & Stanford
Financial Trading in Python — DataCamp, 2025
زبان: فارسی (زبان مادری)، انگلیسی (تسلط حرفه‌ای در محیط کار)