هوتن سیفی

مهندس هوش مصنوعی | توسعه اپلیکیشن‌های LLM و سیستم‌های Agentic AI

تهران | ایمیل: hootanseifi90@gmail.com | تلفن: 0935 775 9499
لینکدین: linkedin.com/in/hootan-seifi-42b180124 | گیت‌هاب: github.com/hootanseifi
نمونه‌کار: hootanseifi.pro

خلاصه حرفه‌ای

مهندس هوش مصنوعی با تمرکز بر طراحی، توسعه، ارزیابی و استقرار اپلیکیشن‌های مبتنی بر مدل‌های زبانی بزرگ (LLM)، سیستم‌های بازیابی اطلاعات (RAG) و عامل‌های هوشمند (AI Agents). دارای تجربه عملی در توسعه گردش‌کارهای عامل‌محور با LangGraph، پیاده‌سازی بازیابی ترکیبی اطلاعات، ارزیابی کیفیت پاسخ مدل‌ها و طراحی سازوکارهای امنیتی و کنترلی برای اپلیکیشن‌های هوش مصنوعی.

دارای نمونه‌کارهای عملی شامل پلتفرم سازمانی AI Agent، سامانه RAG دوزبانه و سیستم شبیه‌سازی معاملات مبتنی بر چند عامل هوشمند. فارغ‌التحصیل کارشناسی ارشد هوش مصنوعی با پیشینه فعالیت در حوزه‌های تحقیق و توسعه، تحلیل فنی نرم‌افزار و تحلیل بازارهای مالی.

مهارت‌های فنی

LLM و توسعه عامل‌های هوشمند: Python، LangGraph، LangChain، OpenAI Agents SDK، CrewAI، MCP، Tool Calling، Prompt Engineering، Structured Outputs، LLM Evaluation، Guardrails

RAG و بازیابی اطلاعات: Embeddings، Chunking، pgvector، PostgreSQL، Chroma، Hybrid Search، BM25، Reranking، RRF، MRR ،Recall@k

Backend و تست: FastAPI، SQLAlchemy، Alembic، REST API، SSE، pytest، Playwright

یادگیری ماشین و داده: PyTorch، scikit-learn، XGBoost، Pandas، SQL، QLoRA، PEFT

زیرساخت و استقرار: Docker، Docker Compose، Linux، Caddy، Git، GitHub Actions، CI/CD

اتوماسیون و هوش تجاری: طراحی Workflow با n8n، Power BI، SQL

Frontend: Next.js، TypeScript

آشنایی: AWS Bedrock، SageMaker، Lambda، Terraform، Modal، Vercel، Spark، Kafka، Airflow

پروژه‌های منتخب

hootanseifi.pro | مجموعه نمونه‌کارهای مهندسی هوش مصنوعی

- توسعه سامانه RAG دوزبانه با قابلیت بازیابی اطلاعات و تولید پاسخ مستند به منابع.
- پیاده‌سازی Hybrid Search با ترکیب BM25 و pgvector و ادغام نتایج با روش Reciprocal Rank Fusion (RRF).
- ارزیابی ۷۲ سناریو شامل کیفیت استناد، وفاداری به منابع، امتناع از پاسخ و مقاومت در برابر Prompt Injection؛ کسب نتیجه موفق در هر ۷۲ سناریو.
- توسعه سیستم شبیه‌سازی معاملات بیت‌کوین با استفاده از ۷ عامل هوشمند مبتنی بر LangGraph و داده‌های لحظه‌ای بازار.
- پیاده‌سازی قوانین مستقل مدیریت ریسک برای AI Agent، شامل حداکثر اهرم 5x، مارجین ۲۰٪ و حد ضرر ۱ تا ۵ درصد. کاربر می‌تواند تنظیمات معاملاتی دلخواه خود را انتخاب کند، اما عامل هوشمند همچنان محدودیت‌های ریسک خودش را رعایت می‌کند.
- ثبت ۲۰ جلسه شبیه‌سازی بدون نقض قوانین مدیریت ریسک تعریف‌شده برای عامل هوشمند.
- توسعه سیستم امتیازدهی تناسب شغلی (Job-fit Scoring) با کنترل محدوده امتیازدهی در کد.
- پیاده‌سازی محدودیت بودجه روزانه و ماهانه برای استفاده از مدل‌های هوش مصنوعی.
- استقرار سرویس‌ها با معماری مبتنی بر Next.js، FastAPI، Worker، PostgreSQL و Caddy روی VPS.
- راه‌اندازی CI/CD با GitHub Actions، تست‌های خودکار، بررسی امنیتی Secretها و آزمایش موفق سازوکار Rollback.

Astra Enterprise AI Agent Platform

- طراحی و توسعه پلتفرم سازمانی عامل هوشمند با FastAPI و LangGraph.
- پیاده‌سازی مسیریابی پویا برای انتخاب بین پاسخ مستقیم، بازیابی RAG، فراخوانی ابزارها و ترکیب RAG با ابزارها.
- توسعه گردش‌کارهای چندمرحله‌ای، مدیریت خطا و بازیابی با Recovery Node، ذخیره وضعیت با PostgreSQL Checkpointer و Human-in-the-Loop.
- پیاده‌سازی RAG مبتنی بر PostgreSQL و pgvector با Hybrid Retrieval، ایندکس HNSW، Reranking و بازیابی مبتنی بر سطح دسترسی کاربران.
- بهبود Recall@1 از 0.67 به 1.00 در مجموعه ارزیابی پروژه.
- پیاده‌سازی احراز هویت و کنترل دسترسی مبتنی بر RBAC/JWT، اعتبارسنجی ورودی ابزارها و شناسایی الگوهای Prompt Injection فارسی و انگلیسی.
- افزودن Secret Redaction، Rate Limiting، مانیتورینگ با Prometheus و ردیابی مصرف توکن و هزینه.
- توسعه MCP Server برای دسترسی استاندارد عامل‌ها به ابزارها.
- دستیابی به ۴۰۷ تست خودکار و ۹۳٪ پوشش کد، همراه با Quality Gate در CI.

Price Estimate | سامانه تخمین قیمت محصولات

- توسعه سامانه تخمین قیمت محصولات با استفاده از مجموعه‌داده‌ای شامل حدود ۸۰۰ هزار محصول Amazon.
- ارزیابی مدل‌های پایه تا شبکه عصبی عمیق Residual برای تخمین قیمت.
- Fine-tuning مدل Llama 3.2 3B با روش QLoRA و ابزارهای Hugging Face TRL و Modal و استفاده از مدل Fine-tuneشده در سیستم.
- پیاده‌سازی RAG با Chroma برای استفاده از اطلاعات محصولات در فرایند تخمین قیمت.
- استفاده از Non-Negative Least Squares (NNLS) برای تعیین وزن مدل‌های Ensemble و بازتنظیم وزن‌ها در صورت نبود خروجی برخی مدل‌ها.
- ارزیابی مدل‌ها با معیارهای MAE، RMSLE، R^2 و Hit Rate و محاسبه فاصله اطمینان ۹۵٪ برای MAE.
- توسعه قابلیت هشدار برای شناسایی فرصت‌های قیمتی و ارائه API با FastAPI و رابط کاربری Gradio.
- پیاده‌سازی بیش از ۶۰ تست خودکار.

AI Medical Notes | دستیار ساخت یادداشت پزشکی

- توسعه اپلیکیشن تبدیل یادداشت‌های ویزیت به خلاصه ساختاریافته، اقدامات بعدی و پیش‌نویس ایمیل بیمار.
- پیاده‌سازی انتقال تدریجی خروجی با Server-Sent Events (SSE).
- توسعه Backend با FastAPI و Frontend با Next.js.
- استفاده از OpenAI API و Clerk برای قابلیت‌های هوش مصنوعی و احراز هویت.
- استقرار اپلیکیشن روی Vercel.

Behengam | پلتفرم یکپارچه سلامت

- مشارکت در طراحی و آماده‌سازی پلتفرم سلامت با هدف ایجاد ارتباط و تبادل اطلاعات میان ۱۲ گروه ذی‌نفع.
- برنامه‌ریزی معماری پرونده سلامت مشترک و تبادل داده بر اساس استانداردهای HL7 v2، FHIR، LOINC و UCUM.
- در نظر گرفتن Django REST Framework و Kafka در معماری فنی پروژه.
- تعریف کاربردهای AI برای شناسایی هشدارها و پشتیبانی از تصمیم‌گیری، با حفظ نقش متخصص سلامت به‌عنوان تصمیم‌گیرنده نهایی.
- پروژه در مرحله آماده‌سازی و طراحی قرار دارد.

سوابق شغلی

مهندس هوش مصنوعی مستقل — مرداد ۱۴۰۵ تا کنون

طراحی، توسعه، تست و استقرار کامل اپلیکیشن‌های مبتنی بر LLM و عامل‌های هوشمند. کد همهٔ پروژه‌ها در گیت‌هاب در دسترس است.

مدیر توسعهٔ محصولات هوش مصنوعی — اقتصادگستر بهسامان — اردیبهشت ۱۴۰۴ تا فروردین ۱۴۰۵

مسئول توسعهٔ محصولات مبتنی بر هوش مصنوعی و همچنین بازاریابی و رشد آن‌ها.

کارشناس ارشد نیروگاه — نیروگاه برق تابان — اسفند ۱۴۰۳ تا اردیبهشت ۱۴۰۴

مسئولیت‌های فنی و نظارت بر عملکرد تجهیزات و فرایندهای عملیاتی نیروگاه.

تحلیلگر بنیادی و معامله‌گر — فناوری‌های نوین اقتصاد — شهریور ۱۴۰۱ تا بهمن ۱۴۰۳

تحلیل بازارهای مالی و رمزارز، ارزیابی پروژه‌های بلاکچینی و تهیهٔ گزارش‌های تحلیلی، و توسعهٔ ربات معامله‌گر با Python بر اساس داده‌های بازار.

کارشناس فنی — کافه‌بازار — دی ۱۴۰۰ تا اردیبهشت ۱۴۰۱

بررسی فنی اپلیکیشن‌ها، ارزیابی کیفیت عملکرد و همکاری در فرایند بررسی و انتشار برنامه‌ها.

کارشناس تحقیق و توسعه — مکو / مپنا — فروردین ۱۳۹۹ تا اسفند ۱۳۹۹

مشارکت در فعالیت‌های تحقیق و توسعه و بررسی فنی پروژه‌های مرتبط با حوزهٔ تخصصی شرکت.

تحصیلات

کارشناسی ارشد مهندسی برق – گرایش هوش مصنوعی — دانشگاه صنعتی امیرکبیر، واحد تفرش — ۱۳۹۷–۱۳۹۵

کارشناسی مهندسی برق – گرایش الکترونیک — ۱۳۹۴–۱۳۹۰

پروژه‌های دانشگاهی منتخب

- تشخیص تقلب در تراکنش‌های Ethereum با استفاده از XGBoost.
- تحلیل احساسات توییت‌ها و بررسی ارتباط آن با قیمت سهام Nvidia با روش‌های NLP و سری زمانی.
- طبقه‌بندی علائم راهنمایی و رانندگی با شبکه عصبی CNN و مجموعه‌داده GTSRB.

دوره‌ها و گواهی‌ها

- LLM Engineering — Ed Donner
- Machine Learning Specialization — Andrew Ng
- Financial Trading in Python — DataCamp

زبان‌ها

- فارسی: زبان مادری
- انگلیسی: مهارت حرفه‌ای در محیط کاری