هوتن سیفی

مهندس هوش مصنوعی ((AI Engineer · سیستم‌های LLM و ایجنتی · Python، FastAPI، LangGraph، RAG

تهران · 0935 775 9499 · hootanseifi90@gmail.com · متولد ۱۳۷۱ · پایان خدمت
سایت و نمونه‌کار زنده: hootanseifi.pro · **گیت‌هاب:** github.com/hootanseifi · **لینکدین:** linkedin.com/in/hootan-seifi-42b180124
آماده همکاری حضوری، دورکاری، ترکیبی و پروژه‌ای

خلاصه

مهندس هوش مصنوعی که سیستم‌های مبتنی بر LLM را از صفر تا استقرار می‌سازد: ایجنت، RAG، ارزیابی، guardrail و استقرار روی سرور. سایت شخصی‌ام، **hootanseifi.pro**، یک سیستم واقعی و زنده است: یک دوقلوی دیجیتال که فقط از رزومه و مستنداتم جواب می‌دهد و یک تیم هفت‌نفره از ایجنت‌های LangGraph که با هزینهٔ هوش مصنوعی حدود **۳ دلار در ماه** کار می‌کنند؛ همراه با ارزیابی با مدل واقعی (۷۲ از ۷۲ و ۲۰ از ۲۰)، **۲۲۵ تست بک‌اند** و CI/CD با بازگشت خودکار. کارشناسی ارشد مهندسی برق گرایش هوش مصنوعی، با سابقهٔ تحقیق و توسعه، بررسی اپلیکیشن و تحلیل بازار مالی که در آن یک ربات معامله‌گر با Python ساختم.

مهارت‌ها

LLM و ایجنت: LangGraph، LangChain، OpenAI Agents SDK، CrewAI، MCP، Tool Calling، Structured Outputs، Prompt Engineering، ارزیابی LLM، Guardrails، PEFT / QLoRA

RAG و بازیابی: PostgreSQL + pgvector، جست‌وجوی ترکیبی (برداری + BM25)، Embedding، Chunking، Reranking، Chroma، MRR / Recall@k

بک‌اند و DevOps: Python، FastAPI، SQLAlchemy، Alembic، REST، SSE، Docker Compose، Caddy، Linux، GitHub Actions، pytest، Playwright

یادگیری ماشین و داده: PyTorch، scikit-learn، XGBoost، Pandas، SQL، Spark، Kafka، Airflow

ابر و فرانت‌اند: AWS (Bedrock، SageMaker، Lambda)، Terraform، Modal، Vercel، Next.js، TypeScript

سوابق کاری

مهندس هوش مصنوعی (پروژه‌های مستقل) — خوداشتغال مرداد ۱۴۰۵ – اکنون

طراحی، ساخت، تست و استقرار اپلیکیشن‌های LLM و ایجنتی به‌صورت کامل. کد همهٔ پروژه‌ها در گیت‌هاب عمومی است.

سایت hootanseifi.pro — نمونه‌کار زنده: دوقلوی دیجیتال، سنجش تناسب شغلی، تیم ترید هوش مصنوعی

- دوقلوی دیجیتال دوزبانه که فقط از مستندات من جواب می‌دهد و منبع را نشان می‌دهد؛ بعد از اندازه‌گیری ضعف بازیابی متن فارسی، جست‌وجوی ترکیبی BM25 و pgvector با Reciprocal Rank Fusion اضافه شد. نتیجهٔ ارزیابی: **۷۲ از ۷۲** سؤال، شامل امتناع و Prompt Injection.
- جلسهٔ روزانهٔ هفت ایجنت با LangGraph که روی قیمت زندهٔ بیت‌کوین معاملهٔ مجازی می‌کند. قوانین ریسک (اهرم حداکثر ۵، مارجین حداکثر ۲۰٪، حد ضرر ۱ تا ۵٪) در کد Python اعمال می‌شود نه در پرامپت: **۲۰ از ۲۰** جلسهٔ ارزیابی بدون نقض قانون.
- سنجش تناسب شغلی که بازهٔ نمره را کد از روی مهارت‌های الزامی تعیین می‌کند تا مدل نتواند تعارف کند؛ دمای صفر برای نتیجهٔ تکرارپذیر.
- هزینهٔ هوش مصنوعی حدود **۳ دلار در ماه** با سقف بودجهٔ روزانه و ماهانه برای هر فراخوانی و طراحی «یک‌بار در روز»: اولین بازدیدکننده جلسه را شروع می‌کند و بقیه بازپخش را می‌بینند.
- استقرار ۵ سرویس (Next.js، Docker، FastAPI، Worker، PostgreSQL، Caddy) روی سرور امن‌شده با پشتیبان‌گیری شبانه. GitHub Actions لینتر، **۲۲۵ تست بک‌اند، ۲۸ تست کامپوننت و ۱۵ تست End-to-End** و اسکن اسرار را اجرا می‌کند و استقرار ناموفق را خودکار برمی‌گرداند (با یک استقرار عمداً خراب آزموده شد).

FastAPI · LangGraph · PostgreSQL + pgvector · SQLAlchemy · Next.js / TypeScript · Docker · Caddy · GitHub Actions

آسترا (Astra) — پلتفرم ایجنت هوش مصنوعی سازمانی github.com/hootanseifi/astra-ai-platform

- ایجنت LangGraph که برای هر درخواست خودش تصمیم می‌گیرد از RAG، ابزار، هر دو یا هیچ‌کدام استفاده کند؛ با Recovery Node، برنامه‌ریزی، Checkpointer روی PostgreSQL و تأیید انسانی برای ابزارهای حساس.
- Agentic RAG روی) pgvectorایندکس HNSW، Reranking و بازیابی بر اساس سطح دسترسی)؛ Reranking معیار Recall@1 را از **۰٫۶۷ به ۱٫۰۰** رساند.
- امنیت و عملیات: اجرای ابزار با RBAC و Allow-list و اعتبارسنجی Schema، احراز هویت JWT، تشخیص Prompt Injection فارسی و انگلیسی، حذف اطلاعات محرمانه، Rate Limiting، متریک‌های Prometheus، ردیابی توکن و هزینه، و MCP Server.
- **۴۰۷ تست با پوشش ۹۳٪** و دروازهٔ ارزیابی در CI) (Recall@k، MRR، دقت مسیریابی، Groundedness).

پیش‌بینی قیمت ((Price Estimate — مدل یادگیری ماشین و ایجنت‌های شکار تخفیف github.com/hootanseifi/price-estimate

- بازپیاده‌سازی پروژهٔ نهایی دورهٔ) LLM Engineeringاد دانر) به‌شکل یک پکیج Python تست‌شده: دیتاست حدود ۸۰۰ هزار محصول آمازون، مدل‌ها از Baseline تا شبکهٔ عصبی عمیق، پایپ‌لاین Fine-tuning با QLoRA برای Llama 3.2 3B (Hugging Face TRL، اجرا روی Modal) و RAG روی Chroma.
- جایگزینی وزن‌های دستی Ensemble با وزن‌های یادگرفته‌شده (NNLS) و وزن‌دهی دوباره در صورت از کار افتادن یک مدل؛ رفع باگ‌های Parser، آپلود و Checkpoint نسخهٔ اصلی.
- مقایسهٔ همهٔ مدل‌ها روی یک مجموعهٔ تست با MAE و بازهٔ اطمینان ۹۵٪، RMSLE، R^2 و Hit Rate. ایجنت‌ها فیدهای تخفیف را می‌خوانند و هشدار می‌فرستند؛ سرویس FastAPI و رابط Gradio با بیش از ۶۰ تست در CI.

AI Medical Notes — نرم‌افزار آنلاین برای پزشکان github.com/hootanseifi/ai-medical-notes-saas

- یادداشت ویزیت پزشک را به خلاصهٔ ویزیت، اقدامات بعدی و ایمیل بیمار تبدیل می‌کند و پاسخ را لحظه‌ای (SSE) نمایش می‌دهد. Next.js، FastAPI، OpenAI، احراز هویت و اشتراک با Clerk، مستقر روی Vercel.

بهنگام — پلتفرم یکپارچهٔ سلامت (بنیان‌گذار، در حال طراحی) دموی تعاملی نسخهٔ ۲

- اتصال ۱۲ نقش نظام سلامت ایران حول یک پروندهٔ مشترک بیمار. ساخت دموی تعاملی برای سرمایه‌گذار و طراحی نقشهٔ راه محصول: دریافت نتایج آزمایش با HL7 v2 و FHIR از طریق Kafka، استانداردسازی LOINC و UCUM، بک‌اند Django REST با دسترسی نقش‌محور، و لایهٔ هشدار هوش مصنوعی که فقط پیشنهاد به پزشک می‌دهد، نه تصمیم.

مدیر بازاریابی دیجیتال و محتوا — اقتصاد گستر بهسامان اردیبهشت ۱۴۰۴ – فروردین ۱۴۰۵

کارشناس ارشد نیروگاه — نیروگاه تأمین انرژی تابان (بانک پاسارگاد) اسفند ۱۴۰۳ – اردیبهشت ۱۴۰۴

تحلیلگر فاندامنتال و معامله‌گر بازارهای مالی — فناوری‌های نوین اقتصاد شهریور ۱۴۰۱ – بهمن ۱۴۰۳

- تحلیل بازارهای مالی و رمزارز، ارزیابی پروژه‌های بلاکچینی و تهیهٔ گزارش تحلیلی، و توسعهٔ ربات معامله‌گر با Python روی داده‌های بازار.

کارشناس فنی بررسی و توسعهٔ اپلیکیشن — کافه‌بازار دی ۱۴۰۰ – اردیبهشت ۱۴۰۱

کارشناس تحقیق و توسعه، واحد R&D — مهندسی و ساخت و کنترل مپنا (مکو) فروردین ۱۳۹۹ – اسفند ۱۳۹۹

تحصیلات

کارشناسی ارشد مهندسی برق، گرایش هوش مصنوعی — دانشگاه امیرکبیر (واحد تفرش) ۱۳۹۵ – ۱۳۹۷

کارشناسی مهندسی برق، گرایش الکترونیک — دانشگاه امیرکبیر (واحد تفرش) ۱۳۹۰ – ۱۳۹۴

پروژه‌های دانشگاهی یادگیری ماشین: تشخیص تقلب در تراکنش‌های اتریوم با داده‌های نامتوازن (XGBoost)؛ اثر احساسات توییت‌ها بر قیمت سهام Nvidia (NLP) و سری زمانی)؛ طبقه‌بندی علائم ترافیکی با CNN (GTSRB).

دوره‌ها و زبان

LLM Engineering: Master AI, Large Language Models & Agents — Ed Donner, Udemy
Machine Learning Specialization — Andrew Ng, DeepLearning.AI & Stanford
Financial Trading in Python — DataCamp, 2025

زبان: فارسی (زبان مادری)، انگلیسی (سطح کاری حرفه‌ای)